

# Overview of Robust Fine-Tuning

Week 37

202111309 손본



## Abstract

해당 분야에서 주로 등장하는 용어에 대한 정리, 앞으로 관련 논문을 읽기 위하여 공부해야할 내용 정리

# Robust Fine-Tuning of Deep Neural Networks with Hessian-based Generalization Guarantees

# Abstract

We study the generalization properties of fine-tuning to understand the problem of overfitting, which has often been observe.

- target dataset is **small**
- training labels are noisy

Existing generalization measures for deep networks depend on notions such as distance from the initialization (i.e., the pretrained network) of the fine-tuned model and noise stability properties of deep networks.

- distance : 모델의 초기(=pretrained network)로부터 fine-tuning을 끝낸 모델의 차이
- noise stability : Adversarial attack 등에 얼마나 강건성을 보이는가

-> 위의 2가지를 일반적으로 현재 신경망이 얼마나 잘 일반화되어있는가를 판단하는 지표로서 많이 사용한다.

# Abstract

This paper identifies a Hessian-based distance measure through PAC-Bayesian analysis, which is shown to correlate well with observed generalization gaps of fine-tuned models

prove **Hessian distance-based generalization bounds for fine-tuned model**

- We present an algorithm and a generalization error guarantee for this algorithm under a class conditional independent noise mode
- Hessian-based distance measure can match the scale of the observed generalization gap of fine-tuned models in practice.

## **fine-tuning**

fine-tuning is common method to using large pre-trained model into real problem.

Understanding the cause of overfitting is challenging since dissecting the issue in practice requires a precise measurement of generalization errors for deep neural networks

# Introduction

## In this work,

In this work, we analyze the generalization error of fine-tuned deep models using PAC-Bayes analysis and data-dependent measurements based on deep net Hessian. With this analysis, we also study the robustness of fine-tuning against label noise

### Note

There is a large body of work concerning generalization in deep neural networks, **whereas less is understood for fine-tuning**

## 선행 연구

These results highlight that **distance from initialization** crucially affects generalization for fine-tuning and informs the design of **distance-based regularization** to mitigate overfitting due to fine-tuning a large model on a small training set

1. 초기 가중치로부터의 거리가 일반화에 결정적으로 영향을 미친다.
2. 거리 기반의 정규화를 사용하여 과적합을 완화할 수 있다.

### Info

distance-based regularization을 이용하여 small train set에 대해 큰 모델을 fine-tuning할 때 발생하는 overfitting 문제를 완화할 수 있다.



## 아이디어 및 접근법들

1. PAC-Bayesian analysis approach
2. deep net Hessian

### Idea

We propose to quantify the stability of a deep model against noise perturbations using Hessian

헤시안을 사용하여 Deep net의 perturbation에 대한 안정성을 정량화하려고 한다.

# Introduction

Hessian distance measure that better captures empirical generalization errors of fine-tuned models.




Figure 1: We identify a Hessian distance measure (cf. equation (1)) that better captures empirical generalization errors of fine-tuned models.

Method	Generalization error bound
Fine-tuning	$\frac{\sum_{i=1}^L \sqrt{v_i^\top \mathbf{H}_i^+ v_i}}{\sqrt{n}}$
Distance-based Reg.	$\frac{\sum_{i=1}^L \sqrt{\text{Tr}[\mathbf{H}_i^+] \cdot \ v_i\ ^2}}{\sqrt{n}}$
Consistent loss w/ Reg.	$\frac{\sum_{i=1}^L \sqrt{\ (F^{-1})^\top\ _{1,\infty} \cdot  \text{Tr}[\mathbf{H}_i]  \cdot \ v_i\ ^2}}{\sqrt{n}}$

Table 1: A summary of the theoretical bounds: To use these results in practice, we can compute Hessian-vector product libraries. See Section 2.1 for the definition of these notations.

=> 즉, 논문에서는 모델이 얼마나 잘 일반화되는지를 이해하기 위해 initial weight에서 얼마나 멀리 떨어져 있는지(=distance)와 Hessian을 모두 고려하여 평가하는 방법을 제안한다. 특히 이는 fine-tuning 과정에서 모델의 일반화 능력을 정확하게 예측하는 데 도움이 될 수 있다.

# Terminology

## generalization gap

보통 모델의 training accuracy와 test accuracy사이의 차이로, 모델의 일반화 성능을 나타내는 지표로서 사용된다.

## noisy labels

Learning with noisy labels means When we say "**noisy labels**," we mean that an **adversary has intentionally messed up the labels**, which would have come from a "clean" distribution otherwise. This setting can also be used to cast learning from only positive and unlabeled data.

## PAC-Bayes analysis

Bayesian learning에서 사용되었으며 현재는 일반적인 상황에도 적용가능하다.  
PAC-Bayes theory gives the tightest known generalization bounds for SVMs !

Study : [lecture\\_PAC-Bayes analysis](#), [An Introduction to PAC-Bayesian Analysis](#), ICML 2021 튜토리얼

## Hessian

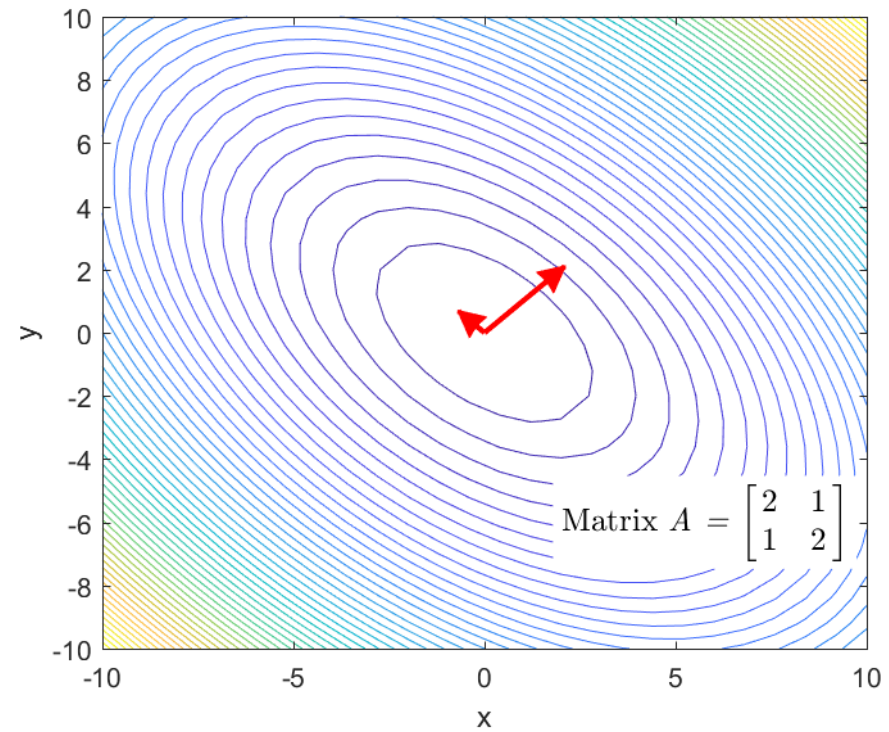

어떤 함수의 이계도함수 를 행렬로 표현한 것  
실함수  $f(x_1, x_2, x_3, \dots, x_n)$ 이 주어졌을 때, **Hessian Matrix**은 다음과 같이 주어진다.

즉, Hessian Matrix의  $H_{ij}$  요소는  $x_i$ 와  $x_j$  변수에 대해 함수를 이차미분한 값이다.

$$H(f) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

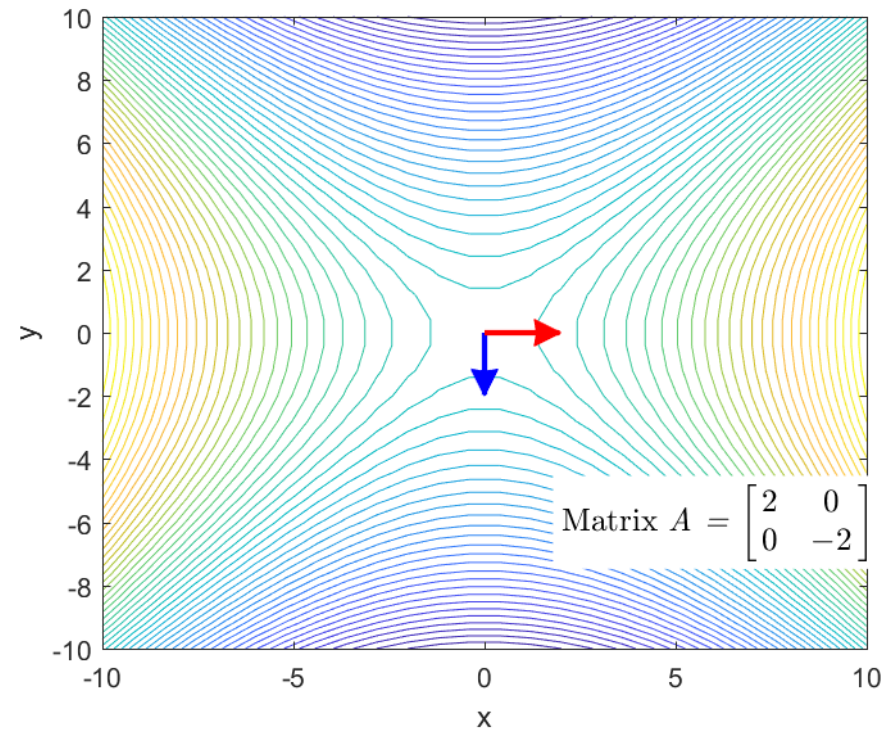

이때, 함수  $f$ 의 이계도함수가 연속이라면 혼합 편미분은 같기 때문에  $f$ 의 이계도함수가 연속이라면 헤세 행렬은 대칭행렬(symmetric matrix)이다.

## 헤시안의 의미



Reference : [헤세 행렬의 기하학적 의미](#)

## 헤시안의 의미



## 헤시안의 의미

- 특정 고유벡터에 대해 고유값의 절댓값의 크기가 클수록 해당 방향으로 더 가파르게 변화한다.
- 헤시안 행렬의 고유값이 모두 양수라면 함수는 아래로 볼록하다. 일차미분이 0이라면 극솟값 ; convex
- 헤시안 행렬의 고유값이 모두 음수라면 함수는 위로 볼록하다. 일차미분이 0이라면 극댓값
- 헤시안 행렬의 고유값에 양수와 음수가 섞여있는 경우라면 함수는 안장의 형태. 일차미분이 0이라면 안장점

## 헤시안의 의미 (한줄 정리)

"헤시안(Hessian)"은 머신러닝과 최적화에서 중요한 역할을 하는 수학적 개념으로, **주어진 함수의 곡률**을 설명하기 위하여 사용된다. 헤시안은 모델(함수)이 가지는 매개변수 공간에서 함수값이 얼마나 빠르게 변화하는지(즉, 얼마나 '곡률이 높은지' 또는 '곡률이 낮은지')를 알려주는 역할을 수행한다.

*Hessian 행렬은 Convex Optimization, 이계도함수 판정, Newton's Method 등의 여러가지 방법에 활용된다.*



# Paper

읽어볼 논문 들 ...

B. Neyshabur, H. Sedghi, and C. Zhang. “What is being transferred in transfer learning?” In: *NeurIPS (2020)* : 전이학습이 왜 가능한지, 어떤 요소가 크게 영향을 미치는지, 전이 학습에서 찾을 수 있는 Optimal point는 어디인지에 대한 연구 <291>

P. Bartlett, D. J. Foster, and M. Telgarsky. “Spectrally-normalized margin bounds for neural networks”. In: *Neural Information Processing Systems (2017)* <1085> : margin bound에 대한 연구 (1)

B. Neyshabur, S. Bhojanapalli, and N. Srebro. “A pac-bayesian approach to spectrally-normalized margin bounds for neural networks”. In: *ICLR (2018)* <590> : margin bound에 대한 연구 (2)

V. Nagarajan and J. Z. Kolter. “Generalization in deep networks: The role of distance from initialization”. In: *arXiv preprint arXiv:1901.01672 (2019)* <76> : generalization 연구

P. M. Long and H. Sedghi. “Generalization bounds for deep convolutional neural networks”. In: *ICLR (2020)* <62> : generalization 연구

D. Li and H. Zhang. “Improved Regularization and Robustness for Fine-tuning in Neural Networks”. In: *NeurIPS (2021)* : fine-tuning을 더욱 효과적으로 하고, 그 과정에서 발생할 수 있는 과적합과 노이즈 문제를 해결하기 위한 새로운 방법론을 제안 (with few-shot learning) <26>

논문에서 핵심적으로 언급한 기술에 대한 논문

## PAC-Bayesian analysis approach

- B. Neyshabur, S. Bhojanapalli, and N. Srebro. “A pac-bayesian approach to spectrally- normalized margin bounds for neural networks”. In: ICLR (2018)
- [S. Arora, R. Ge, B. Neyshabur, and Y. Zhang. “Stronger generalization bounds for deep nets via a compression approach”. In: International Conference on Machine Learning. 2018](#)

## deep net Hessian

- [Z. Yao, A. Gholami, K. Keutzer, and M. W. Mahoney. “Pyhessian: Neural networks through the lens of the hessian”. In: IEEE International Conference on Big Data. 2020](#)

PYHESSIAN은 딥 러닝 신경망에 대한 헤시안(즉, 2차 미분) 정보의 빠른 계산을 가능하게 하는 프레임 워크이다. 이를 이용하면 신경망의 loss landscape의 토폴로지를 이해하기 위한 정보를 얻을 수 있다. (곡률)